

Федеральное государственное бюджетное образовательное учреждение  
высшего образования  
«Саратовский государственный технический университет  
имени Гагарина Ю.А.»

Институт прикладных информационных технологий и телекоммуникаций

Кафедра «Информационно-коммуникационные системы  
и программная инженерия»

Направление «Информатика и вычислительная техника»

**Проект на тему:  
«Атрибуция картин прерафаэлитов»**

Выполнили студенты  
Группы мИВЧТ-11  
Кудряшов Алексей Владимирович  
Щуковский Денис Владимирович

Саратов 2024

## Содержание

Введение.....	3
1. Математические методы распознавания образов.....	5
1.1. Метод предположения о классе решающих функций .....	6
1.2. Логические методы.....	6
1.3. Лингвистические (структурные) методы .....	7
1.4. Метод сравнения с прототипом .....	7
1.5. Метод k–ближайших соседей.....	8
1.6. Алгоритмы вычисления оценок .....	8
1.7. Коллективы решающих правил.....	9
1.8. Сверточная нейронная сеть .....	9
2. Атрибуция живописи прерафаэлитов .....	10
2.1. Братство прерафаэлитов .....	11
2.2. Особенности стиля прерафаэлитов.....	12
3. Реализация нейронной сети.....	17
3.1. Выбор технологий .....	17
3.1.1. MobileNetV2 .....	17
3.2. Подготовка датасета .....	19
3.3. Обучение нейронной сети .....	21
3.4. Оценка результатов .....	23
Заключение .....	25
Список использованных источников .....	26

## **Введение**

Данная работа посвящена изучению и разработке модели алгоритма, использующего нейронную сеть, для распознавания произведений художников-прерафаэлитов. Обученная нейросеть будет способна распознавать, является ли предоставленное пользователем изображение оригинальным произведением художника-прерафаэлиты на основе некоего ряда характеристик, определенного и категорированного в процессе непосредственного проектирования нейронной сети.

Творчеству прерафаэлитов присущ весьма характерный и детализированный стиль, который часто трудно определить и анализировать с использованием традиционных методов. Нейросети же способны обнаруживать сложные структуры и узнавать уникальные характеристики, что делает их мощным инструментом для атрибуции.

В целом, применение автоматизированных алгоритмов распознавания картинных произведений позволяет однозначно упростить процесс атрибуции, сократив затрачиваемое время и ресурсы, при использовании их в качестве вспомогательных инструментов. В перспективе же, подобные алгоритмы могут в точности показаний и вовсе превзойти классический человеческий подход, что станет незаменимым для широкого спектра людей, имеющих отношение к искусству.

Цель работы заключается в описании и проектировании алгоритма по распознаванию картин художников-прерафаэлитов, с последующим обучением нейронной сети.

Исходные данные:

- изображение картины;
- метаданные картины: материал, происхождение, возраст, признаки износа;

Требования:

- вычисление вероятности определения подлинности картины с заданной точностью( $P > 0.8$ )

Для достижения цели поставлен следующий ряд задач:

- Изучение методов распознавания образов;
- Определение рассматриваемых художников-прерафаэлитов;
- Описание особенностей стиля художников-прерафаэлитов;
- Подготовка рабочего датасета картин;
- Обучение распознающей нейронной сети с точностью 80%
- Анализ полученных результатов

## **1. Математические методы распознавания образов**

Распознавание представляет собой информационный процесс, реализуемый некоторым преобразователем информации (т.н. системой распознавания), имеющим вход и выход. На вход системы подается информация о том, какими признаками обладают предъявляемые объекты. На выходе системы отображается информация о том, к каким классам система относит распознаваемые объекты.

Распознаванием образов называются задачи построения и применения формальных операций над числовыми или символьными отображениями некоторых объектов, результаты решения которых отражают отношения эквивалентности между этими объектами. Отношения эквивалентности выражают принадлежность оцениваемых объектов к каким-либо классам, рассматриваемым как самостоятельные семантические единицы. В общем виде, методы распознавания образов можно разделить на две основные категории: интенциональные и экстенциональные.

Характерной особенностью интенциональных методов является то, что в качестве элементов операций при построении и применении алгоритмов распознавания образов они используют различные характеристики признаков. Подобными элементами могут быть отдельные значения или интервалы значений признаков, средние величины и дисперсии, матрицы связей признаков и т. п., над которыми производятся действия, выражаемые в аналитической или конструктивной форме. При этом объекты в данных методах не рассматриваются как целостные информационные единицы, а выступают в роли индикаторов для оценки взаимодействия и поведения своих атрибутов. Группа интенциональных методов распознавания образов довольно обширна, и её деление на подклассы носит в некой степени условный характер.

В методах экстенциональной группы, в отличие от интенционального направления, каждому изучаемому объекту в большей или меньшей мере придается самостоятельное диагностическое значение. По своей сути эти

методы близки к клиническому подходу, который рассматривает людей не как проранжированную по тому или иному показателю цепочку объектов, а как целостные системы, каждая из которых индивидуальна и имеет особенную диагностическую ценность.

### **1.1. Метод предположения о классе решающих функций**

В данной группе методов считается известным общий вид решающей функции и задан функционал ее качества. На основании этого функционала по обучающей последовательности находят наилучшее приближение решающей функции.

Основным достоинством подобных методов является ясность непосредственной математической постановки задачи распознавания (задача поиска экстремума). Обобщением рассматриваемых алгоритмов, к которым относятся, в частности, алгоритм Ньютона, перцептроны и др., является метод стохастической аппроксимации.

Достаточно высокое качество решающего правила может быть достигнуто даже с помощью алгоритмов, не имеющих строгого математического доказательства сходимости решения к глобальному экстремуму. К таким алгоритмам относится большая группа процедур эвристического программирования, представляющих направление эволюционного моделирования

### **1.2. Логические методы**

Логические методы распознавания образов основаны на аппарате алгебры логики и позволяют оперировать информацией, заключенной не только в отдельных признаках, но и в сочетаниях значений признаков. В этих методах значения какого-либо признака рассматриваются как элементарные события.

В общем виде логические методы могут быть определены как способ поиска логических закономерностей в обучающей выборке и формирования системы логических решающих правил. Эти правила могут представлять

собой, например, конъюнкции элементарных событий, каждое из которых имеет свой вес. Группа логических методов разнообразна и включает в себя методы с различной сложностью и глубиной анализа. Для булевых признаков распространены такие классификаторы, как древообразные, метод тупиковых тестов, алгоритм "Кора" и другие.

### **1.3. Лингвистические (структурные) методы**

Лингвистические методы распознавания образов основаны на использовании специальных грамматик, порождающих языки, с помощью которых может описываться совокупность свойств распознаваемых объектов. Для различных классов объектов выделяются неприводимые (атомарные) элементы (подобразы, признаки) и возможные отношения между ними. Грамматикой же уже являются правила построения комплексных объектов из этих неприводимых элементов.

Путем синтаксического анализа (грамматического разбора) "предложения" определяется его синтаксическая "правильность" - может ли некоторая фиксированная грамматика, описывающая класс, породить имеющееся корректное описание объекта. Впрочем, задача определения грамматик по определенному множеству высказываний (описаний объектов), порождающих язык, трудно формализуема.

### **1.4. Метод сравнения с прототипом**

Применяется в случаях, когда распознаваемые классы можно отобразить в пространстве признаков компактными геометрическими группировками. В таком случае обычно в качестве точки – прототипа выбирается центр геометрической группировки класса (или ближайший к центру объект).

Для классификации неизвестного объекта находится ближайший к нему прототип, и объект относится к тому же классу, что и этот прототип. Очевидно, никаких обобщенных образов классов в данном методе не формируется.

При применении данного метода распознавания, основанный на сравнении с прототипами диагностических классов, возникает ряд сложностей. Во-первых, это принцип определения меры близости (метрику), от которой непосредственно зависит пространственная конфигурацию распределения объектов. Во-вторых, это непосредственная проблема анализа многомерных структур экспериментальных данных. Обе эти проблемы становятся особенно острыми в условиях высокой размерности пространства признаков, что характерно для реальных задач.

### **1.5. Метод k–ближайших соседей**

При классификации неизвестного объекта находится заданное число ( $k$ ) геометрически ближайших к нему в пространстве признаков других объектов (ближайших соседей) с уже известной принадлежностью к распознаваемым классам. Решение об отнесении неизвестного объекта к тому или иному диагностическому классу принимается путем анализа информации об этой известной принадлежности его ближайших соседей, например, с помощью простого подсчета голосов.

Первоначально метод  $k$ –ближайших соседей рассматривался как непараметрический метод оценивания отношения правдоподобия. Для этого метода получены теоретические оценки его эффективности в сравнении с оптимальным байесовским классификатором. Доказано, что асимптотические вероятности ошибки для метода  $k$ –ближайших соседей превышают ошибки правила Байеса не более чем в два раза. Однако, главным недостатком данного метода является необходимость представления ограниченного числа объектов в обучающей выборке, так как это уменьшает представительность обучающей выборки.

### **1.6. Алгоритмы вычисления оценок**

В отличие от ранее рассмотренных методов, алгоритмы вычисления оценок (АВО) принципиально по-новому оперируют описаниями объектов. Для этих алгоритмов объекты существуют одновременно в самых разных



подпространства пространства признаков. Поскольку не всегда известно, какие сочетания признаков наиболее информативны, то в АВО степень сходства объектов вычисляется при сопоставлении всех возможных или определенных сочетаний признаков, входящих в описания объектов. Используемые сочетания признаков обозначаются опорными множествами или множествами частичных описаний объектов.

В данных алгоритмах задача определения сходства и различия объектов формулируется как параметрическая и выделен этап настройки АВО по обучающей выборке, на котором подбираются оптимальные значения введенных параметров. Критерием качества служит ошибка распознавания, а параметризуется широкий перечень характеристик, которые задаются в виде пороговых значений.

### **1.7. Коллективы решающих правил**

Так как различные алгоритмы распознавания проявляют себя по-разному на одной и той же выборке объектов, то закономерно встает вопрос о синтетическом решающем правиле, адаптивно использующем сильные стороны этих алгоритмов. В синтетическом решающем правиле применяется двухуровневая схема распознавания. На первом уровне работают частные алгоритмы распознавания, результаты которых объединяются на втором уровне в блоке синтеза. Наиболее распространенные способы такого объединения основаны на выделении областей компетентности того или иного частного алгоритма.

### **1.8. Сверточная нейронная сеть**

Сверточные нейронные сети (convolutional CNN) - это широко применяемый метод в области распознавания изображений, который активно используется в современных моделях глубокого обучения. Эти сети обладают уникальной способностью автоматического извлечения сложных признаков из изображений и могут эффективно обучаться на обширных наборах размеченных данных. идея сверточных нейронных сетей заключается в

чередовании сверточных слоёв и слоёв подвыборки. Структура сети — однонаправленная (без обратных связей), принципиально многослойная.

Работу сверточной нейронной сети обычно трактуют как процесс перехода от конкретных деталей изображения к более абстрактным характеристикам, затем к еще более абстрактным элементам, вплоть до формирования высокоуровневых понятий. В этом процессе сеть автоматически настраивается, создавая иерархию абстрактных признаков (последовательность карт признаков), фильтруя незначительные детали и выделяя существенные черты.

Эта интерпретация имеет в основе скорее метафорический или иллюстративный характер. Фактические признаки, формируемые сложной сетью, часто сложны для понимания и интерпретации настолько, что на практике часто не пытаются анализировать или корректировать эти признаки. Вместо этого для улучшения результатов распознавания часто производят изменения в структуре и архитектуре сети. Гораздо чаще игнорирование системой неких явлений, который могут быть охарактеризованы человеком как существенные, обычно сводится к банальной нехватке данных для обучения, или же явных дефектов самой структуры сети, в результате которых система не может сформировать эффективные признаки для этих явлений.

## **2. Атрибуция живописи прерафаэлитов**

Прежде чем рассматривать творчество прерафаэлитов, стоит отметить семантическую особенность термина — технически, под него подпадает, как и первоначальное «братство прерафаэлитов» — группы из семи художников, сформированной в 1848 году, так и более широкий перечень единомышленников, действовавших после распада первоначального общества в 1853 году. В данной работе рассматривается именно первая категория, однако дальнейшее включение более расширенного перечня является перспективным направлением для последующих работ.

## 2.1. Братство прерафаэлитов

Первоначальное «братство прерафаэлитов» было основано в 1848 году Джоном Милле, Данте Россетти и Уильямом Хантом, знакомыми друг с другом по выставкам Королевской академии художеств. Общие взгляды на современное искусство, в частности деградирующее, по их мнению, состояние английской живописи, а также презрение к академизму, основоположником которого они считали Рафаэля привели к формированию оппозиционного по отношению к принятым художественным течениям сообщества. Вскоре после формирования, в сообщество были приглашены Джеймс Коллинсон, Томас Вулнер, Фредерик Стивенс и Уильям Россетти (рис. 1).



Рисунок 1 - Члены братства прерафаэлитов: Т. Вулнер, Д. Милле, Д. Уоллинсон, У. Россетти, Ф. Стивенс, Д. Россетти, У. Хант

Уильям Россетти обозначил четыре основные принципа, сформировавших доктрину творчества прерафаэлитов:

- иметь подлинные идеи для выражения;
- внимательно изучать природу, чтобы знать, как её изобразить;

- отдавать приоритет прямоте, серьезности и искренности, характерных предшествующему искусству, исключая обыденное и самопоказное;
- «и, что самое главное, создавать действительно хорошие картины и статуи».

Подобные нечеткие формулировки символизировали важность личной ответственности каждого художника при выборе сюжетов и подходов к их отображению, что было результатом сильного влияния идей романтизма.

После шквала критики, обрушившегося в равной степени на само братство, его членов и принципы, дальнейшее направление творчества было во многом определено вмешательством уважаемого художественного критика и историка искусства Джона Рёскина, положительные отзывы и непосредственные финансовое спонсирование Россетти и Милле. В качестве идеала Рёскин выдвигал средневековое искусство, таких мастеров Раннего Возрождения, как Перуджино, Фра Анжелико, Джованни Беллини, и побуждал художников «писать картины с чистым сердцем, ни на что не ориентируясь, ничего не выбирая и ничем не пренебрегая».

## **2.2. Особенности стиля прерафаэлитов**

С самого начала Братство испытывало недовольство по поводу воздействия на современное искусство таких художников, как сэр Джошуа Рейнольдс, Дэвид Уилки и Бенджамин Хейдон. Это недовольство дополнительно усиливалось тем, что в то время многие художники использовали битум, который придавал изображению мутный и темный характер.



Рисунок 2 - Битва между Ираклием и Хосровом. П. Франческа, 1466 г.

Прерафаэлиты, напротив, стремились вернуться к высокой детализации и глубоким цветам итальянских живописцев эпохи Кватроченто (в качестве примера приведена картина Пьеро Делла Франческа «Битва между Ираклием и Хосровом», рис. 2). Они отказались от "кабинетной" живописи, предпочитая работать на природе, и внесли изменения в традиционные методы. Применяя слой белил на загрунтованный холст, прерафаэлиты намечали композицию, затем убирали масло промокательной бумагой, добавляли полупрозрачные краски поверх белил. Эта техника позволяла им достигнуть ярких и свежих тонов, а также оказалась настолько долговечной, что их работы сохранились в первозданном виде до наших дней.





Рисунок 3 - Юность Девы Марии. Д. Россетти, 1849 г.

Прерафаэлиты предпочитали выбирать в качестве моделей своих друзей или родственников. Например, на полотне "Юность Девы Марии" (рис. 3) Россетти изобразил свою мать и сестру Кристину, а на картинах, таких как "Изабелла", современники могли узнать друзей и знакомых Милле из Братства. Более того, прерафаэлиты изменили динамику отношений между художником и моделью, превратив их в равноправных партнеров. В отличие от персонажей картин Рейнольдса, которые почти всегда одеты соответственно своему социальному статусу, Россетти мог изображать королеву с продавщицей или богиню с дочерью конюха. Например, для картины "Леди Лилит" (рис. 4) он использовал в качестве модели домохозяйку Фанни Корнфорт.



Рисунок 4 - Леди Лилит. Д. Россетти, 1866 г.

Поначалу прерафаэлиты предпочитали евангельские сюжеты, избегая при написании картин церковного характера и трактовали Евангелие символически, придавая особое значение не исторической верности изображаемых евангельских эпизодов, а их внутреннему философскому смыслу. Помимо этого, они занимались и историческими темами, обращались к произведениям классической поэзии и литературы, к творчеству Данте Алигьери, Уильяма Шекспира («Фердинанд, соблазняемый Ариэлем», рис. 5), Джона Китса. Они идеализировали Средневековье, любили средневековую романтику и мистику.





Рисунок 5 - Фердинанд, соблазняемый Ариэлем. Д. Милле, 1850 г.



### **3. Реализация нейронной сети**

#### **3.1. Выбор технологий**

Для работы по обучению нейросети выбран язык Python и библиотеки Keras, Scikit-learn, а также вспомогательная библиотека NumPy.

NumPy обеспечивает эффективные алгоритмы и удобный синтаксис для работы с числовыми данными, что делает его незаменимым инструментом в области научных и инженерных вычислений на языке Python.

Keras — это открытая библиотека для машинного обучения, представляющая собой удобный интерфейс для создания и обучения различных моделей глубокого обучения, в частности нейронные сети. Keras ориентирован на простоту в использовании и удобство быстрого прототипирования моделей. Он может быть использован как надстройка над другими библиотеками глубокого обучения, такими как TensorFlow, Theano или Microsoft Cognitive Toolkit (CNTK). Keras предоставляет простые и интуитивно понятные функции для создания, обучения, оценки и использования моделей глубокого обучения. Он поддерживает различные типы слоев, функций активации, оптимизаторов и других компонентов, необходимых для построения и настройки нейронных сетей.

Scikit-learn содержит реализации множества алгоритмов машинного обучения для задач классификации, регрессии, кластеризации, а также инструменты для предобработки данных, выбора признаков, оценки моделей и многое другое.

##### **3.1.1. MobileNetV2**

В качестве основы взята базовая сверточная нейронная сеть архитектуры MobileNetV2. Эта архитектура является улучшенной версией оригинальной MobileNet, предназначенной для эффективного выполнения на устройствах с ограниченной вычислительной мощностью и ограниченным объемом памяти.

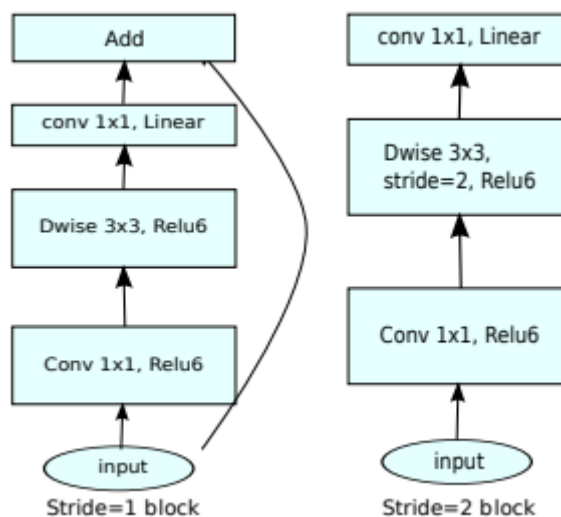


Рисунок 6 - структура блоков MobileNetV2

MobileNetV2 была представлена в статье "Inverted Residuals and Linear Bottlenecks" в 2018 году. Эта архитектура включает в себя несколько инноваций, таких как инвертированные остаточные блоки и линейные бутылочные горлышки, общая структура блока MobileNetV2 представлена на рисунке 6.

В общем виде блок MobileNet, классифицированный авторами как «расширяющий сверточный блок» (expansion convolution), состоит из трёх слоёв: сначала идёт точечное свертывание (pointwise convolution) с большим количеством каналов, называемый слой расширения (expansion layer). Затем идёт глубинное свертывание (depthwise convolution) с ReLU6-активацией. Этот слой вместе с предыдущим, по сути, образует классический блок MobileNetV1. В конце уже идёт 1x1-свертка с линейной функцией активации, понижающая число каналов.

На входе первый слой принимает тензор размерности  $D_f * D_f * C_{in}$ , а на выходе выдает тензор  $D_f * D_f * (t * C_{in})$ , где  $t$  — новый гиперпараметр, названный уровнем расширения (expansion factor). Авторы рекомендуют задавать этому гиперпараметру значение от 5 до 10, где меньшие значения лучше работают для более маленьких сетей, а большие — для более крупных. Он создает отображение входного тензора в пространстве большой размерности. Авторы называют такое отображение «целевым многообразием» (в оригинале «manifold of interest»).

Второй слой принимает тензор размерности  $D_f * D_f * (t * C_{in})$ , а на выходе выдает тензор  $(D_f/s) * (D_f/s) * (t * C_{in})$ , где  $s$  — шаг свертки (stride).

На входе третий слой принимает тензор размерности  $(D_f/s) * (D_f/s) * (t * C_{in})$ , а на выходе выдает тензор  $(D_f/s) * (D_f/s) * C_{out}$ , где  $C_{out}$  — количество каналов на выходе блока. Фактически, именно третий слой в этом блоке, называемый линейным бутылочным горлышком, и является основным отличием второго поколения MobileNet от первого.

В отличие от классических остаточных блоков, используемых в многих глубоких сетях, MobileNetV2 использует блоки с "обратным остатком". Они включают в себя легкую сверточную сеть с узкими слоями и более полными свертками.

MobileNetV2 показывает хорошие результаты в задачах классификации изображений и других задачах компьютерного зрения, при этом имея низкое количество параметров и вычислительную эффективность.

Также при выборе архитектуры сети также рассматривалась MobileNetV3, однако она не продемонстрировала значительных преимуществ в данной категории задач, несмотря на заявленные повышенные показатели точности и производительности.

### **3.2. Подготовка датасета**

Для выполнения цели проекта, а именно: атрибуция картин прерафаэлитов необходим датасет с картинами прерафаэлитов и картин других художников. Подобный датасет не был найден в открытом доступе, поэтому стала очевидна необходимость подготовки собственного датасета. Для этого были предприняты следующие шаги:

#### **1. Организация файлов:**

Создана основная папка с подпапками-категориями *original* - включает в себя картины непосредственного братства художников прерафаэлитов, *fake* - другие картины известных авторов, которые не относятся к прерафаэлитовому направлению.

## 2. Копирование фотографий:

Для поиска фотографий использовались источники интернета с картинками. Такие, как: веб-сайт музеев, статьи, поиск по картинкам. Картины были размещены по своим категориям в соотношении 70% - original, 30% - fake. Примеры использованных картин приведены на рисунке 7.

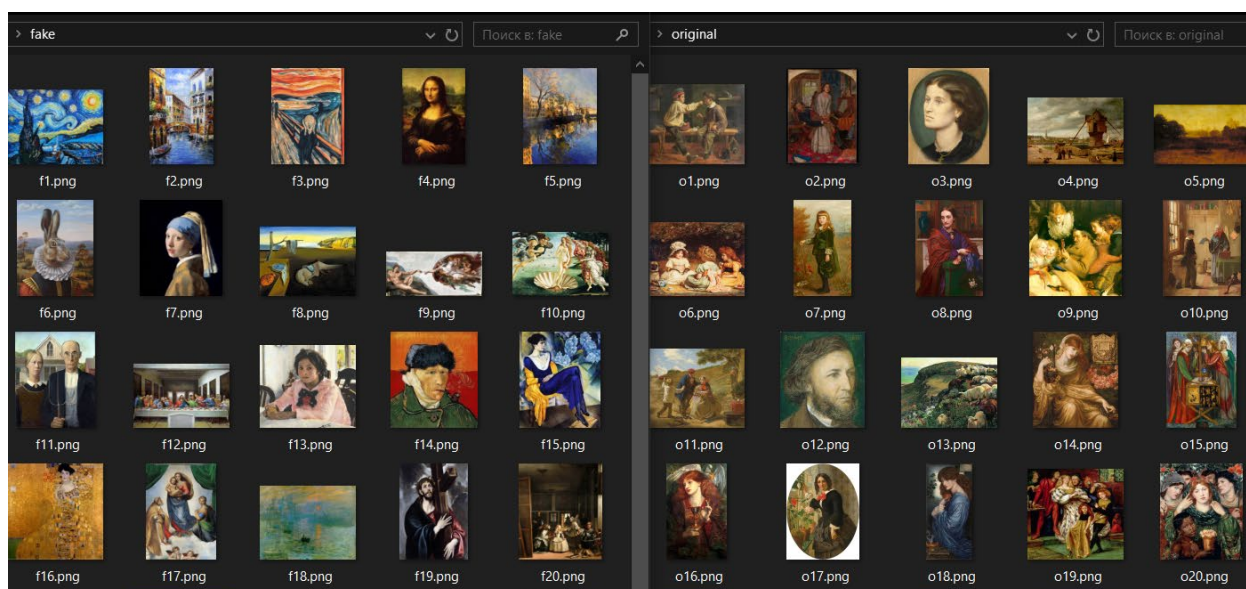


Рисунок 7 - Примеры использованных картин

## 3. Разделение на тренировочный, валидационный и тестовый наборы данных:

Для разделения датасета на тренировочный, валидационный и тестовые наборы данных использовалась программа, которая в случайном порядке разделяет фотографии в соотношении 70/15/15. Структура файла получается следующая: основная папка, 3 подпапки с наборами, в каждом наборе идет разделение на original и fake категории. Пример разделения показан на рисунке 8.

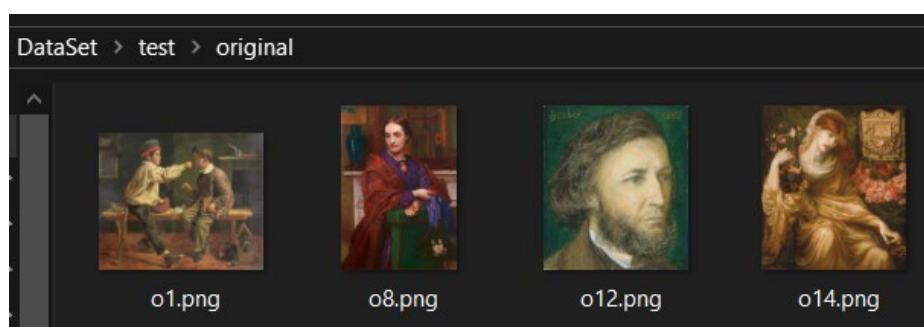


Рисунок 8 - Тестовый набор, содержащий картины прерафаэлитов

#### 4. Проверка изображений на целостность:

Все изображения имеют формат PNG, открываются, не имеют поврежденных данных. Размеры изображения автоматически корректируются в коде нейросети.

### 3.3. Обучение нейронной сети

Для повышения точности моделей использовался метод ранней остановки:

```
early_stopping = EarlyStopping(monitor='val_loss', patience=3,  
restore_best_weights=True)
```

Метод ранней остановки (Early Stopping) используется в обучении нейронных сетей для предотвращения переобучения модели. Его основная идея заключается в том, чтобы прекращать обучение, когда значение функции потерь на валидационном наборе перестает улучшаться, а начинает ухудшаться или остается стабильным в течение определенного числа эпох.

Для эффективного обучения нейронных сетей важно правильно подготовить данные. В данном коде используется мощный инструмент — генератор изображений, предоставляемый библиотекой Keras. Этот подход позволяет автоматизировать и улучшить процесс подачи данных в модель.

```
# Создание генератора изображений для тренировочного набора  
train_datagen = ImageDataGenerator(  
    rescale=1./255, # Масштабирование значений пикселей для нормализации  
    shear_range=0.2, # Диапазон сдвига изображения (shear)  
    zoom_range=0.2, # Диапазон масштабирования изображения (zoom)  
    horizontal_flip=True # Горизонтальное отражение изображений  
)
```

Для улучшения обучения модели используется нормализация значений пикселей. Для создания тестового набора используется функция `shuffle`, чтобы модели можно было использовать для ансамблирования. Использование нескольких псевдослучайных независимых наборов предоставляет максимальное разнообразие для обучения отдельных элементов ансамбля.

```
shuffle=True    # Перемешивание данных для повышения разнообразия
```

Обучение модели:

```
Epoch 6/10
3/3 [=====] - 10s 3s/step - loss: 0.3092 - accuracy: 0.8333 - val_loss: 0.4784 - val_accuracy: 0.8000
Epoch 7/10
3/3 [=====] - 7s 2s/step - loss: 0.1155 - accuracy: 0.9697 - val_loss: 0.6523 - val_accuracy: 0.6000
Epoch 8/10
3/3 [=====] - 8s 4s/step - loss: 0.1516 - accuracy: 0.9545 - val_loss: 0.5346 - val_accuracy: 0.6667
Training Model 5
Epoch 1/10
3/3 [=====] - 14s 4s/step - loss: 0.7706 - accuracy: 0.4848 - val_loss: 0.5168 - val_accuracy: 0.7333
Epoch 2/10
3/3 [=====] - 9s 2s/step - loss: 0.5239 - accuracy: 0.8030 - val_loss: 0.5259 - val_accuracy: 0.6667
Epoch 3/10
3/3 [=====] - 9s 4s/step - loss: 0.2762 - accuracy: 0.8939 - val_loss: 0.4831 - val_accuracy: 0.8000
Epoch 4/10
3/3 [=====] - 7s 2s/step - loss: 0.2415 - accuracy: 0.8636 - val_loss: 0.5313 - val_accuracy: 0.8000
Epoch 5/10
3/3 [=====] - 9s 4s/step - loss: 0.1382 - accuracy: 0.9697 - val_loss: 0.5849 - val_accuracy: 0.8000
Epoch 6/10
3/3 [=====] - 9s 4s/step - loss: 0.2212 - accuracy: 0.8939 - val_loss: 0.6291 - val_accuracy: 0.8000
Epoch 7/10
3/3 [=====] - 14s 7s/step - loss: 0.0853 - accuracy: 1.0000 - val_loss: 0.8369 - val_accuracy: 0.6667
Epoch 8/10
3/3 [=====] - 7s 2s/step - loss: 0.0817 - accuracy: 0.9848 - val_loss: 0.7567 - val_accuracy: 0.7333
1/1 [=====] - 3s 3s/step
1/1 [=====] - 2s 2s/step
1/1 [=====] - 2s 2s/step
1/1 [=====] - 2s 2s/step
1/1 [=====] - 2s 2s/step
Ensemble Accuracy: 0.85
```

В коде ниже приводится реализация нескольких моделей для формирования ансамбля. Этот подход позволяет объединить преимущества различных моделей и повысить обобщающую способность.

```
# Создание списка для хранения моделей
models = []
num_models = 5 # Задайте количество моделей в ансамбле

# Итерация для создания каждой модели
for _ in range(num_models):
    # Загрузка предварительно обученной модели (MobileNetV2 в данном
    # случае)
    base_model = MobileNetV2(weights='imagenet', include_top=False,
    input_shape=(224, 224, 3))

    # Добавление своего классификатора поверх предварительно обученной
    # модели
    x = base_model.output
    x = GlobalAveragePooling2D()(x)
    x = Dense(128, activation='relu')(x)
    predictions = Dense(train_generator.num_classes, activation='softmax')(x)
```

```
# Создание модели, объединяющей предварительно обученную часть и
новый классификатор
model = Model(inputs=base_model.input, outputs=predictions)

# Замораживание слоев предварительно обученной модели
for layer in base_model.layers:
    layer.trainable = False


# Компиляция модели с выбранным оптимизатором и функцией потерь
model.compile(optimizer=Adam(learning_rate=0.001),
loss='categorical_crossentropy', metrics=['accuracy'])

# Добавление модели в список
models.append(model)
```

Каждая модель в ансамбле обучается на тренировочных данных, а затем их предсказания объединяются (усредняются), что может привести к улучшенной производительности и повышенной устойчивости к разнообразным входным данным.

### 3.4. Оценка результатов

В результате выполнения кода по созданию моделей нейросети получились 5 обученных моделей, каждая модель обучалась на случайно перемешанных тренировочных данных. Согласно средствам аналитики scikit-learn, точность ансамбля, по оценкам нейросети, достигает 85% (рис. 9).



Ensemble Accuracy: 0.85

Рисунок 9 - Полученная точность ансамбля

Проверка на случайно подобранных картинках из интернета:

```
1/1 [=====] - 1s 965ms/step
1/1 [=====] - 1s 977ms/step
1/1 [=====] - 1s 975ms/step
1/1 [=====] - 1s 978ms/step
1/1 [=====] - 1s 1s/step
Изображение: car.png, Предсказанный класс: 0
Вероятность предсказанного класса: 0.8342493
1/1 [=====] - 0s 81ms/step
1/1 [=====] - 0s 83ms/step
1/1 [=====] - 0s 83ms/step
1/1 [=====] - 0s 82ms/step
1/1 [=====] - 0s 85ms/step
Изображение: man.png, Предсказанный класс: 0
Вероятность предсказанного класса: 0.6593469
1/1 [=====] - 0s 80ms/step
1/1 [=====] - 0s 87ms/step
1/1 [=====] - 0s 76ms/step
1/1 [=====] - 0s 79ms/step
1/1 [=====] - 0s 78ms/step
Изображение: pre.png, Предсказанный класс: 1
Вероятность предсказанного класса: 0.7288103
```

Рисунок 10 - Результаты тестирования на произвольных изображениях

Использованные изображения:

- car.png - фото машины, совсем не относящееся к картинам;
- man.png - портрет мужчины, не относящийся к творчеству прерафаэлитов;
- pre.png - картина в стиле прерафаэлитов, автор - Артур Хьюз “Орфелия”



## **Заключение**

В результате работы выполнена первоначальная цель - описан и предложен алгоритм по распознаванию картин художников-прерафаэлитов, и обучена нейронная сеть, способная распознавать картины данных художников с точностью 80%. Для достижения цели был выполнен следующий ряд задач:

1. Изучены методы распознавания образов. Определен выбранный метод распознавания образов, предварительно подобрана искомая архитектура нейросети;
2. Определен перечень рассматриваемых художников-прерафаэлитов;
3. Описаны ключевые особенности стиля художников-прерафаэлитов, которые в дальнейшем могут быть использованы при более подробной категоризации;
4. Самостоятельно подготовлен рабочий датасет картин, состоящий из перечня картин художников-прерафаэлитов, а также других известных художников, не относящихся к данному движению. Датасет разделен на тренировочный, валидационный и тестовый набор;
5. Обучена распознающая нейронная сеть, являющаяся ансамблем из 5 моделей, основанных на архитектуре MobileNetV2;
6. Проведен анализ полученных результатов. Достигнутый показатель 85% является выполненной задачей в получении точности минимум 80%;
7. Определены дальнейшие потенциальные векторы развития проекта.

В целом, данное направление можно считать перспективным для дальнейшей работы. При должном уровне обучения, данный алгоритм сможет послужить превосходным вспомогательным инструментом, позволяющим упростить процесс атрибуции, сократив затрачиваемое время и ресурсы, что станет незаменимым для широкого спектра людей, имеющих непосредственное отношение к изучению искусства.

## Список использованных источников

1. Васильев В.И. Конструирование пространств в процессе обучения распознаванию образов// Автоматика. – 1982. - №5. – С.18-27.
2. Васильев В.И., Овсянникова Ф.П., Бекмуратов К.А. Разделяющая сила признаков в задачах обучения распознаванию методом предельных упрощений.// Автоматика. – 1987. - №4, С.12-20.
3. Журавлев Ю.И. Об алгебраическом подходе к решению задач распознавания или классификации // Проблемы кибернетики. – М.: Наука, 2005. – Вып. 33. – С. 5-68.
4. Ковалевский В.А. Методы оптимальных решений в распознавании изображений. – М.: Наук, 1967 – 327 с.
5. Latham, David, *Haunted Texts: Studies in Pre-Raphaelitism in Honour of William E. Fredeman*, William Evan Fredeman, David Latham — изд. University of Toronto Press, 2003 — 267 с.
6. Нордау, Макс. Прерафаэлиты // Вырождение. М.: Республика, 1995.— 400 с.— (Прошлое и настоящее). ISBN 5-250-02539-0
7. MobileNetV2: Inverted Residuals and Linear Bottlenecks // Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2018, с. 4510-4520
8. Ансамбли нейронных сетей с PyTorch и Sklearn. URL(дата обращения 12.01.2024 г.): <https://habr.com/ru/articles/489058/>
9. MobileNet: меньше, быстрее, точнее. URL (дата обращения 13.01.2024 г.): <https://habr.com/ru/articles/352804/>